

Conceptos bayesianos para leer los papers de la IPre

Apunte breve

1. El escenario: datos, latentes y parámetros

Casi todos los papers de la IPre (VAE, VQ-VAE, DreamCoder, LPN) comparten el mismo esqueleto:

- $\mathbf{x}$: lo *observado* (una imagen, una tarea, pares input–output).
- $\mathbf{z}$: una variable *latente*, no observada, que “explica” a $\mathbf{x}$ (un código, un programa).
- θ : parámetros del modelo (pesos del decoder, una librería $L \dots$).

Modelo generativo (historia de cómo se generan los datos)

$$p_{\theta}(\mathbf{x}, \mathbf{z}) = \underbrace{p(\mathbf{z})}_{\text{prior}} \underbrace{p_{\theta}(\mathbf{x} | \mathbf{z})}_{\text{verosimilitud}}.$$

Se lee como un procedimiento: *primero* se sortea $\mathbf{z} \sim p(\mathbf{z})$, *luego* se genera $\mathbf{x} \sim p_{\theta}(\mathbf{x} | \mathbf{z})$. En un VAE, $p_{\theta}(\mathbf{x} | \mathbf{z})$ es el **decoder**.

2. Regla de Bayes y su vocabulario

Regla de Bayes

$$\underbrace{p(\mathbf{z} | \mathbf{x})}_{\text{posterior}} = \frac{\overbrace{p(\mathbf{x} | \mathbf{z})}^{\text{verosimilitud}} \overbrace{p(\mathbf{z})}^{\text{prior}}}{\underbrace{p(\mathbf{x})}_{\text{evidencia}}}, \quad p(\mathbf{x}) = \int p(\mathbf{x} | \mathbf{z}) p(\mathbf{z}) d\mathbf{z}.$$

- **Prior** (*a priori*) $p(\mathbf{z})$: qué creemos sobre $\mathbf{z}$ *antes* de ver el dato.
- **Verosimilitud** (*likelihood*) $p(\mathbf{x} | \mathbf{z})$: qué tan bien un $\mathbf{z}$ dado explica el dato $\mathbf{x}$. Ojo: como función de $\mathbf{z}$ (con $\mathbf{x}$ fijo) *no* es una densidad en $\mathbf{z}$.
- **Posterior** (*a posteriori*) $p(\mathbf{z} | \mathbf{x})$: qué creemos sobre $\mathbf{z}$ *después* de ver $\mathbf{x}$. “Inferir” = calcular (o aproximar) la posterior.
- **Evidencia** o **verosimilitud marginal** $p(\mathbf{x})$: probabilidad del dato promediando sobre todos los $\mathbf{z}$. Es la constante que normaliza la posterior, y *también* lo que se quiere maximizar al entrenar.

Intuición

Posterior $\propto$ verosimilitud $\times$ prior: la posterior es un compromiso entre lo que los datos sugieren y lo que creíamos de antemano. Si la verosimilitud no depende de $\mathbf{z}$ (el dato no dice nada sobre $\mathbf{z}$), la posterior queda *igual* al prior. Guarda esta última frase: es exactamente el *posterior collapse* (Sección 6).

Marginalizar es “sumar/integrar afuera” una variable que no nos interesa: $p(\mathbf{x}) = \sum_{\mathbf{z}} p(\mathbf{x}, \mathbf{z})$. Cuando $\mathbf{z}$ es continuo y de alta dimensión, o un programa (espacio combinatorio), esta suma es **intratable**. De ahí nace todo lo que sigue.

3. Aprender: máxima verosimilitud y MAP

Estimadores puntuales

$$\text{MLE: } \hat{\theta} = \arg \max_{\theta} \sum_i \log p_{\theta}(\mathbf{x}_i),$$

$$\text{MAP: } \hat{\mathbf{z}} = \arg \max_{\mathbf{z}} \log p(\mathbf{x} | \mathbf{z}) + \log p(\mathbf{z}) = \arg \max_{\mathbf{z}} p(\mathbf{z} | \mathbf{x}).$$

- MLE sobre θ con datos $\mathbf{x}_i \sim p_{\text{data}}$ equivale a acercar $p_{\theta}(\mathbf{x})$ a $p_{\text{data}}(\mathbf{x})$.
- MAP es “el modo de la posterior”. Notar que **no necesita la evidencia** $p(\mathbf{x})$, porque no depende de $\mathbf{z}$.
- El término $\log p(\mathbf{z})$ actúa como **regularizador**. Por ejemplo, con un prior gaussiano en los pesos aparece el *weight decay*.
- **Prior y longitud de descripción:** si $p(\rho) \propto 2^{-|\rho|}$, entonces $-\log p(\rho)$ es (salvo constantes) la longitud de ρ . Un prior así prefiere lo *corto*: es la navaja de Occam en versión probabilística (y la idea de MDL).

En la IPre

En DreamCoder, la fase *wake* puntúa programas con $\log Q_{\theta}(\rho | x) + \log P(\rho | L)$, donde $\log P(\rho | L) \approx -|\rho|_L$: un prior que favorece programas cortos *en la librería actual*. La fase de abstracción $L^* = \arg \max_L [\log P(L) + \sum_x \log P(\rho_x^* | L)]$ es un MAP sobre la librería: prior sobre L (librerías chicas) + verosimilitud de los programas encontrados.

4. Divergencia KL

Divergencia de Kullback–Leibler

$$D_{\text{KL}}(q \| p) = \mathbb{E}_{\mathbf{z} \sim q} \left[\log \frac{q(\mathbf{z})}{p(\mathbf{z})} \right].$$

Propiedades que se usan sin decirlo:

- $D_{\text{KL}}(q \| p) \geq 0$, con igualdad sii $q = p$ (casi en todas partes).
- **No es simétrica:** $D_{\text{KL}}(q \| p) \neq D_{\text{KL}}(p \| q)$ en general, así que no es una distancia.
- La esperanza es bajo q : penaliza fuerte que q ponga masa donde p casi no tiene.

5. Inferencia variacional, ELBO y amortización

Como la posterior verdadera $p_{\theta}(\mathbf{z} | \mathbf{x})$ es intratable (por $p(\mathbf{x})$), se **aproxima** con una familia manejable $q_{\phi}(\mathbf{z} | \mathbf{x})$ (p. ej. gaussianas diagonales). Esa es la **posterior aproximada** o **variacional**; en un VAE es el **encoder**.

La identidad central

Para cualquier q_ϕ ,

$$\log p_\theta(\mathbf{x}) = \underbrace{\mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})}[\log p_\theta(\mathbf{x}, \mathbf{z}) - \log q_\phi(\mathbf{z} | \mathbf{x})]}_{\mathcal{L}_{\theta, \phi}(\mathbf{x}) \text{ (ELBO)}} + \underbrace{D_{\text{KL}}(q_\phi(\mathbf{z} | \mathbf{x}) \| p_\theta(\mathbf{z} | \mathbf{x}))}_{\geq 0}.$$

Por lo tanto $\mathcal{L} \leq \log p_\theta(\mathbf{x})$: es una cota inferior de la evidencia (*Evidence Lower BOund*).

Maximizar la ELBO hace dos cosas a la vez: sube $\log p_\theta(\mathbf{x})$ (aprender θ) y baja la KL a la posterior verdadera (mejorar la inferencia ϕ). Reescribiendo $p_\theta(\mathbf{x}, \mathbf{z}) = p(\mathbf{z})p_\theta(\mathbf{x} | \mathbf{z})$ se obtiene la forma que aparece en el código:

$$\mathcal{L}_{\theta, \phi}(\mathbf{x}) = \underbrace{\mathbb{E}_{q_\phi(\mathbf{z}|\mathbf{x})}[\log p_\theta(\mathbf{x} | \mathbf{z})]}_{\text{reconstrucción}} - \underbrace{D_{\text{KL}}(q_\phi(\mathbf{z} | \mathbf{x}) \| p(\mathbf{z}))}_{\text{regularización hacia el prior}}.$$

Ojo: hay *dos* KL distintas dando vueltas: contra la posterior verdadera (en la identidad) y contra el prior (en la pérdida). El β -VAE pondera la segunda con β .

Inferencia amortizada

En vez de resolver una optimización distinta para cada $\mathbf{x}$, se entrena *una sola* red $\mathbf{x} \mapsto q_\phi(\mathbf{z} | \mathbf{x})$ que sirve para todos los datos. El costo de la inferencia se “amortiza” durante el entrenamiento; a cambio, aparece un error de aproximación (*amortization gap*).

En la IPre

- **VAE:** encoder = $q_\phi(\mathbf{z} | \mathbf{x})$ amortizado; decoder = $p_\theta(\mathbf{x} | \mathbf{z})$; prior $p(\mathbf{z}) = \mathcal{N}(0, I)$.
- **LPN:** el encoder da una posterior amortizada sobre programas latentes, y en test se *refina* $\mathbf{z}$ por gradiente sobre la log-verosimilitud del decoder: es cerrar parte del *amortization gap* con búsqueda.
- **DreamCoder:** $Q_\theta(\rho | x)$ es un modelo de reconocimiento, o sea, una posterior aproximada amortizada sobre programas. En *dreaming* se entrena con “fantasías”: se muestrea $\rho \sim P(\rho | L)$ (el prior), se ejecuta para obtener x , y se enseña a Q_θ a recuperar ρ desde x . Esa es la idea del algoritmo *wake-sleep* original: usar el modelo generativo para entrenar la inferencia.

6. Posterior collapse e identificabilidad

Posterior collapse

La posterior (aproximada o verdadera) coincide con el prior: $q_\phi(\mathbf{z} | \mathbf{x}) = p(\mathbf{z})$ para todo $\mathbf{x}$. Entonces el término KL vale 0, pero $\mathbf{z}$ no lleva información del dato: el decoder lo ignora.

Mirado con Bayes es inmediato: si $p_\theta(\mathbf{x} | \mathbf{z})$ no depende de $\mathbf{z}$, se cancela en numerador y denominador y queda $p(\mathbf{z} | \mathbf{x}) = p(\mathbf{z})$. Esa es la intuición del resultado de Wang et al.: *colapso* $\iff$ *no-identificabilidad* del latente (distintos $\mathbf{z}$ dan la misma verosimilitud, así que el dato no puede distinguirlos).

VQ-VAE: la posterior es determinista (one-hot en el código más cercano) y el prior es uniforme sobre K códigos. Entonces la KL contra el prior es una constante que no depende de θ, ϕ : ya no hay una fuerza que empuje q hacia el prior.

7. Glosario rápido

Término	Objeto	VAE / DreamCoder
Prior	$p(\mathbf{z})$	$\mathcal{N}(0, I)$ / $P(\rho \mid L)$, que favorece programas cortos
Verosimilitud	$p_\theta(\mathbf{x} \mid \mathbf{z})$	decoder / ¿el programa produce los outputs?
Posterior verdadera	$p_\theta(\mathbf{z} \mid \mathbf{x})$	intratable / programas que explican la tarea
Posterior aproximada	$q_\phi(\mathbf{z} \mid \mathbf{x})$	encoder / modelo de reconocimiento Q_θ
Evidencia	$p_\theta(\mathbf{x})$	lo que se quiere maximizar; se acota con la ELBO
MAP	$\arg \max_{\mathbf{z}} p(\mathbf{z} \mid \mathbf{x})$	mejor programa en <i>wake</i> ; L^* en abstracción

8. Para comprobar que se entendió

1. Demuestra la identidad central de la Sección 5. *Pista:* escribe $\log p_\theta(\mathbf{x}) = \mathbb{E}_q[\log p_\theta(\mathbf{x})]$ (no depende de $\mathbf{z}$) y usa $p_\theta(\mathbf{x}) = p_\theta(\mathbf{x}, \mathbf{z})/p_\theta(\mathbf{z} \mid \mathbf{x})$.
2. Pasa de la ELBO “ $\mathbb{E}_q[\log p(\mathbf{x}, \mathbf{z}) - \log q]$ ” a la forma reconstrucción – KL.
3. En VQ-VAE, calcula $D_{\text{KL}}(q(\mathbf{z} \mid \mathbf{x}) \parallel p(\mathbf{z}))$ con q one-hot y p uniforme sobre K códigos. ¿Por qué el resultado no depende de los parámetros?
4. ¿Por qué MAP no necesita calcular $p(\mathbf{x})$, pero el entrenamiento de θ sí la necesita (o una cota)?