Las seis preguntas de la presentación

Contenido necesario y preguntas guía para llegar a la respuesta

IPre Sueño-Vigilia y Compositional Learning (IMT2985, 2026-2) | Kevin Cardemil Ulloa

Cómo usar este apunte

Cada pregunta tiene cuatro tipos de recuadros. **Contenido** y **Herramienta** entregan lo que necesitas saber (definiciones, fórmulas, hechos de los papers) y que no está, o está incompleto, en tus notas. **Evidencia** cita resultados concretos de los papers. **Preguntas guía** es una secuencia: cada pregunta usa la anterior, y la última te pide redactar la respuesta. El apunte *no* contiene las respuestas: lo que puedes calcular, está planteado para que lo calcules.

Las referencias a «tus notas» son al PDF `Notes/main.pdf` y las de «la presentación», a las diapositivas.

¿Alcanzan tus notas para responder?

	Lo que ya tienes	Lo que falta (y se agrega aquí)	¿Alcanza?
P1	RSSM, ciclo de aprendizaje, Gumbel-Softmax y estimador ST.	Forma exacta de z_t, pérdidas KL con *free bits* y *unimix*, y evidencia empírica sobre por qué ayudan los latentes discretos.	No
P2	Definiciones, teorema de Wang et al. y criterio de Li et al.	Los ejemplos del paper de Wang (los omitiste), condicionamiento gaussiano y el caso del decoder expresivo.	A medias
P3	Arquitectura y pérdida de VQ-VAE.	*Codebook collapse*, el rol real de β, actualización EMA y perplejidad.	No
P4	$D_{\mathrm{KL}} = \log K$ y la ELBO.	KL gaussiana en forma cerrada, posterior agregada y la descomposición en información mutua.	No
P5	Los cuatro modelos están resumidos.	El rol de la KL en DreamerV3 y la lectura de DreamCoder como máquina de Helmholtz.	Casi
P6	Arquitectura de NLI, $\mathcal{L}_{\mathrm{reg}}$ y tu hipótesis.	Resultados y ablaciones del paper (tu sección «Resultados» de NLI está vacía).	A medias

Cuidado: tres errores en tus notas que afectan estas preguntas

1. **Signo de la ELBO** (notas, p. 23): escribes $\log p_\theta(x) = \mathcal{L}_{\theta,\phi}(x) - D_{\mathrm{KL}}(q_\phi(z|x) \,\|\, p_\theta(z|x))$. Tu propia derivación (y la diapositiva 10) da un $+$. Esto importa en P4.
2. **Pérdida de compromiso** (notas, p. 28): dices que «regula el crecimiento de K» y que las K categorías «irán creciendo». En VQ-VAE, K está fijo. El paper dice: *«since the volume of the embedding space is dimensionless, it can grow arbitrarily if the embeddings e_i do not train as fast as the encoder parameters. To make sure the encoder commits to an embedding and its output does not grow, we add a commitment loss»*. Lo que se controla es la norma de $z_e(x)$, no K. Esto importa en P3.
3. **Signo de la pérdida de VQ-VAE**: el paper (ec. 3) escribe $L = \log p(x|z_q(x)) + \dots$ y la presentación lo copia. Como se *minimiza* L, el primer término debería ser $-\log p(x|z_q(x))$. Es un desliz conocido del paper.

Pregunta 1: DreamerV3 y latentes discretos

Pregunta 1 (diap. 50)

¿Qué hace que un modelo de mundo con latentes discretos (vectores de categóricas entrenadas con gradientes *straight-through*) funcione mejor que uno con latentes gaussianos continuos?

Contenido: cómo es exactamente z_t

- z_t es un vector de L variables categóricas, cada una con C clases. Se representa como L vectores *one-hot* concatenados. En DreamerV3, C = «codes per latent» $= d/16$ (de 16 a 96 según el tamaño del modelo), y L está fijo entre tamaños. DreamerV2 usaba $L = C = 32$.
- **Straight-through (sin Gumbel):** se muestrea $k \sim \mathrm{Cat}(p)$ y se usa

$$\hat{z} = \mathrm{onehot}(k) + p - \mathrm{sg}(p).$$

  Hacia adelante, $\hat{z}$ vale el one-hot. Hacia atrás, el gradiente pasa como si $\hat{z} = p$. A diferencia del estimador Gumbel-ST de tus notas, aquí no hay temperatura ni annealing.
- **Unimix:** $p = 0.99 \cdot \mathrm{softmax}(\ell) + 0.01 \cdot \frac{1}{C}$. Así, ninguna clase tiene probabilidad menor que $0.01/C$.

Contenido: las pérdidas del modelo de mundo (ec. 2–3 del paper)

$$\mathcal{L}(\phi) = \mathbb{E}_{q_\phi}\Big[\textstyle\sum_t \beta_{\text{pred}}\mathcal{L}_{\text{pred}} + \beta_{\text{dyn}}\mathcal{L}_{\text{dyn}} + \beta_{\text{rep}}\mathcal{L}_{\text{rep}}\Big], \qquad \beta_{\text{pred}} = 1,\ \beta_{\text{dyn}} = 1,\ \beta_{\text{rep}} = 0.1,$$

$$\mathcal{L}_{\text{dyn}} = \max\big(1,\ D_{\text{KL}}[\mathrm{sg}(q_\phi(z_t|h_t, x_t)) \,\|\, p_\phi(z_t|h_t)]\big),$$
$$\mathcal{L}_{\text{rep}} = \max\big(1,\ D_{\text{KL}}[q_\phi(z_t|h_t, x_t) \,\|\, \mathrm{sg}(p_\phi(z_t|h_t))]\big).$$

El $\max(1, \cdot)$ son los *free bits*: bajo 1 nat (≈ 1.44 bits) la KL deja de dar gradiente. El paper los justifica así: *«to avoid a degenerate solution where the dynamics are trivial to predict but fail to contain enough information about the inputs»*. Aquí la «prior» no es fija: es el predictor $p_\phi(z_t|h_t)$, que se aprende.

Evidencia de los papers: Meyer, White y Machado (2024), en tu carpeta `Additional/2312.01203v3.pdf`

1. Los modelos de mundo sobre representaciones discretas (VQ-VAE) predicen con más exactitud las transiciones *poco frecuentes* en los datos de entrenamiento (sec. 3.2.1).
2. La ventaja *desaparece* cuando el modelo de mundo es suficientemente grande. Sólo aparece cuando la capacidad es limitada respecto al mundo (sec. 3.2.2, fig. 3).
3. Con el mismo VQ-VAE (misma información), representar los latentes como *multi-one-hot* supera ampliamente a representarlos como vectores cuantizados e_k. Según los autores, lo que importa no es la «discretitud», sino que la representación sea *binaria y rala* (sec. 3.2.3, fig. 4).

Preguntas guía

1. Con $L = C = 32$, ¿cuántos valores distintos puede tomar z_t? ¿Cuántos bits son como máximo? Compáralo con el máximo de 1 nat que «perdonan» los free bits.
2. **Multimodalidad.** Desde un mismo h_t, el siguiente estado puede ser A o B con probabilidad $\frac{1}{2}$ cada uno, con posteriores q concentradas en z_A y z_B (lejanos). Si $p_\phi(\hat{z}|h) = \mathcal{N}(\mu, \sigma^2 I)$ se ajusta por máxima verosimilitud a muestras que valen z_A o z_B con probabilidad $\frac{1}{2}$ (es lo que hace $\mathcal{L}_{\text{dyn}}$, que minimiza $D_{\text{KL}}(\text{sg}(q) \,\|\, p)$), ¿qué μ y σ resultan? ¿Qué estados genera el modelo al *imaginar*? ¿Y si p_ϕ es categórica?
3. Generaliza lo anterior: una mezcla de categóricas sobre C clases, ¿qué tipo de distribución es? ¿Y una mezcla de gaussianas? Conecta esto con la *posterior agregada* $q(z) = \mathbb{E}_x q(z|x)$ de la Pregunta 4.
4. El predictor de DreamerV3 es factorizado entre las L categóricas. ¿Qué distribuciones sobre z_t no puede representar? ¿Qué rol cumple entonces $\mathcal{L}_{\text{rep}}$, que empuja a q hacia p?
5. **Saltos bruscos.** En Atari, al derrotar a un enemigo aparece otro de golpe. Con un decoder suave y z gaussiano, ¿qué relación hay entre cambios pequeños de z y cambios en $\hat{x}$? ¿Ese sesgo es bueno o malo para transiciones discontinuas?
6. **Estabilidad de la KL.** Con unimix, acota $D_{\text{KL}}(q \,\|\, p)$ entre dos categóricas de C clases (pista: $p_k \geq 0.01/C$). Evalúa la cota para $C = 32$. ¿Existe una cota así entre dos gaussianas? ¿Por qué el paper menciona «picos» en la KL?
7. **Free bits y colapso.** Describe en tus palabras la «solución degenerada» que evitan los free bits. ¿Es un *posterior collapse* según la definición de Wang et al.? (Ojo: aquí la prior también se mueve).
8. **Gradientes.** El estimador ST es sesgado y la reparametrización gaussiana no. ¿Qué otras propiedades (escala de las entradas, acotamiento, ralidad) podrían compensar ese sesgo? Usa el punto 3 de Meyer et al.
9. Lee la sec. 3.2.3 de Meyer et al. ¿Qué parte de tu explicación sobrevive a ese experimento: la discretitud, la ralidad o la forma binaria?
10. **Redacción.** Escribe 3 o 4 mecanismos candidatos. Para cada uno, indica qué evidencia lo apoya (paper y experimento) y si es un hecho demostrado o una hipótesis. Después compara con las hipótesis de DreamerV2 (sección sobre latentes discretos).

Fuente: Hafner et al. (2023), arXiv:2301.04104, sec. «World model learning» y tabla de hiperparámetros. Meyer et al. (2024), arXiv:2312.01203. Para contrastar al final: Hafner et al. (2021), *Mastering Atari with Discrete World Models*, arXiv:2010.02193 (no está en tu carpeta).

Pregunta 2: Ejemplos de posterior collapse

Pregunta 2 (diap. 21)

Construye ejemplos pequeños (pocas dimensiones, calculables a mano) de modelos de variable latente en los que ocurra colapso posterior, y explica intuitivamente por qué ocurre en cada uno.

Contenido: dos niveles de colapso

- **Colapso de la posterior exacta:** $p(z|x;\hat{\theta}) = p(z)$. Por el Teorema de Wang et al., equivale a que $p(x|z;\hat{\theta})$ no dependa de z. Es un problema *del modelo y de los datos*, no de la inferencia variacional.
- **Colapso de la posterior aproximada:** $q_\phi(z|x) = p(z)$ aunque la exacta no colapse. Wang et al. advierten que puede pasar si la familia variacional es demasiado restrictiva.
- **Colapso parcial:** sólo algunas coordenadas de z cumplen lo anterior.

Herramienta: condicionamiento gaussiano en 1D

Si $z \sim \mathcal{N}(0,1)$ y $x|z \sim \mathcal{N}(wz, \sigma^2)$, entonces

$$p(x) = \mathcal{N}\big(0,\ w^2+\sigma^2\big), \qquad p(z|x) = \mathcal{N}\Big(\frac{w\,x}{w^2+\sigma^2},\ \frac{\sigma^2}{w^2+\sigma^2}\Big).$$

(Puedes verificarlo completando cuadrados en $p(z)p(x|z)$.)

Evidencia de los papers: Wang et al. (2021), sec. 2.2 y apéndice A

- **GMVAE con $K = 2$:** un maximizador de la verosimilitud recupera los dos clusters. Otro pone ambos componentes iguales a la marginal de los datos. Los dos explican los datos igual de bien, pero sólo en el segundo colapsa z.
- **PPCA con latente 2D y datos generados con 1D:** una solución óptima pone $w = [0, \bar{w}_1]$. Colapsa *sólo* la primera coordenada.
- **GMM con peso global $\alpha \sim$ Beta$(5,5)$:** si los clusters se solapan, la posterior de α queda *casi* igual a la prior.

Ejemplo A: ruido versus señal (lineal, 1D)

Datos $x \sim \mathcal{N}(0, \xi^2)$. Modelo $z \sim \mathcal{N}(0,1)$, $x|z \sim \mathcal{N}(wz, \sigma'^2)$ con σ'^2 *fijo* (hiperparámetro).

1. Escribe $\mathbb{E}_x[\log p(x;w)]$ como función de w. ¿Qué w^* la maximiza? Separa en casos según ξ^2 y σ'^2.
2. Con w^*, calcula $p(z|x)$. ¿En qué caso es igual a $p(z)$? Compara la condición con el criterio $\sigma'^2 > \max_i \xi_i^2$ de Li et al.
3. Pasa a $x \in \mathbb{R}^N$ con covarianza de valores propios $\xi_1^2 \geq \cdots \geq \xi_N^2$ y latente $z \in \mathbb{R}^N$. ¿Qué coordenadas colapsan si $\xi_2^2 < \sigma'^2 < \xi_1^2$?

Ejemplo B: componentes indistinguibles

$z \in \{1, 2\}$ uniforme y $x|z \sim \mathcal{N}(\mu_z, 1)$.

1. Si los datos vienen de $\mathcal{N}(0, 1)$, muestra que $\mu_1 = \mu_2 = 0$ maximiza la verosimilitud. Calcula $p(z = 1|x)$.
2. ¿Y si los datos vienen de $\frac{1}{2}\mathcal{N}(-5, 1) + \frac{1}{2}\mathcal{N}(5, 1)$? Calcula $p(z = 1|x = 5)$ en el óptimo, al menos aproximadamente.
3. ¿Qué tiene que ver el resultado con que $p(x|z)$ sea o no inyectiva en z?

Ejemplo C: decoder demasiado expresivo

$x = (x_1, x_2) \in \{0, 1\}^2$ con $x_1 \sim \text{Bern}(\frac{1}{2})$ y $x_2 = x_1$. Latente $z \in \{0, 1\}$ con prior uniforme. Compara dos decoders: (i) factorizado, $p(x_1|z)\, p(x_2|z)$; (ii) autorregresivo, $p(x_1|z)\, p(x_2|x_1, z)$.

1. Calcula $\mathbb{E}[\log p_{\text{data}}(x)]$. Es la mejor log-verosimilitud posible.
2. Para (i), ¿cuál es la mejor ELBO si el decoder ignora z? ¿Y si $q(z|x)$ copia x_1? (Calcula el término de reconstrucción y la KL por separado.)
3. Repite para (ii). ¿Qué solución gana? Si hay empate, ¿qué la desempata en la práctica? Piensa en una q que no puede ser exactamente determinista, como una gaussiana, y en qué término de la ELBO da gradiente desde el primer paso.

Síntesis

1. Para A, B y C: ¿colapsa la posterior exacta o sólo la aproximada? ¿Todo z o algunas coordenadas?
2. Clasifica la causa de cada ejemplo: datos, ruido, decoder u optimización. ¿Cuál de las preguntas de la diap. 21 responde cada uno?
3. Redacta la intuición de cada ejemplo en una o dos frases, sin fórmulas.

Fuente: Wang et al. (2021), arXiv:2301.00537, sec. 2.2, 4.2 y ap. A. Li et al. (2025), arXiv:2510.01621, sec. 4. Para el Ejemplo C: Chen et al. (2017), *Variational Lossy Autoencoder*, arXiv:1611.02731 (argumento de «bits-back»; no está en tu carpeta).

Pregunta 3: VQ-VAE y posterior collapse

Pregunta 3 (diap. 23)

Se dice que VQ-VAE evita el colapso posterior. ¿En qué casos un VQ-VAE igualmente termina ignorando todo o parte de su espacio latente?

Contenido: quién recibe gradiente en VQ-VAE

- **Codebook:** el término $\| \mathrm{sg}[z_e(x)] - e\|_2^2$ sólo afecta al e_k *elegido* por el arg min. Los demás no reciben gradiente.
- **Versión EMA (ap. A.1 del paper):** e_i se actualiza como el promedio móvil de las $z_e(x)$ asignadas a él (como en k-means). Si a e_i no se le asigna nada ($n_i = 0$), no se mueve.
- **Encoder:** recibe el gradiente de reconstrucción copiado desde $z_q(x)$ (straight-through) y el de compromiso, $\beta\|z_e(x) - \mathrm{sg}[e]\|^2$, que lo atrae hacia el código elegido.
- **Decoder:** sólo recibe el gradiente de reconstrucción.

Contenido: uso del codebook y perplejidad

La *distribución de uso* es $\hat{q}(k) = \frac{1}{N}\sum_n q(z = k|x_n)$, es decir, la posterior agregada empírica. Su *perplejidad* es $\exp(H(\hat{q})) \in [1, K]$: el «número efectivo de códigos usados». Se habla de **codebook collapse** o **códigos muertos** cuando la perplejidad es mucho menor que K.

Evidencia de los papers: lo que afirman los papers

- VQ-VAE define el colapso posterior como *«the latents are ignored when they are paired with a powerful autoregressive decoder»* y afirma no sufrirlo, incluso con decoder PixelCNN (sec. 4.2).
- En ese mismo experimento (DeepMind Lab, 2 etapas), la segunda etapa usa 3 latentes con $K = 512$: *«compressing the image onto 3×9 bits»*. Las texturas *«are generated procedurally by the PixelCNN»*.
- El paper de NLI (sec. 4.3) dice que el estimador ST de VQ-VAE sufre gradientes sesgados, *codebook collapse* (*«many codebook entries remain unused»*, Huh et al., 2023) y desfase entre las salidas del encoder y el codebook (Łańcucki et al., 2020).

Preguntas guía

1. **Juguete.** $x \in \{-1, +1\}$ equiprobable, encoder fijo $z_e(x) = x$, $K = 2$, con inicialización $e_1 = 0.1$ y $e_2 = 5$. ¿A qué código se asigna cada x? ¿Hacia dónde converge e_1? ¿Y e_2? ¿Qué recibe el decoder para $x = -1$ y para $x = +1$?
2. En ese juguete, calcula $\hat{q}$, la perplejidad y la información mutua $I_q(x; z)$. Pista: si $q(z|x)$ es determinista, $H(z|x) = 0$ (ver P4).
3. Ahora deja que el encoder aprenda. ¿Dónde está la frontera de Voronoi entre e_1 y e_2? El gradiente copiado desde z_q, ¿puede llevar $z_e(+1)$ a cruzarla? ¿Ayuda o estorba el término de compromiso? ¿Qué cambia con β grande o pequeño?
4. Propón dos maneras de inicializar o actualizar el codebook que eviten el juguete anterior. Después compáralas con lo que hacen Łańcucki et al. (2020) o Dhariwal et al. (2020,

Jukebox).

5. **¿Es posterior collapse?** En el juguete, ¿$q(z|x) = p(z)$ con p uniforme? ¿$q(z|x)$ depende de x? Distingue «la posterior se iguala a la prior» de «la posterior se vuelve constante en x». ¿Cuál de las dos captura la definición de tus notas?
6. **Decoder potente.** Si un decoder PixelCNN puede modelar x casi sin mirar z_q, ¿qué gradiente le llega al encoder? Si el decoder ignora del todo z_q, $p(x|z)$ es constante en z. Por el Teorema de Wang, ¿qué pasa con la posterior *exacta* del modelo, aunque $q(z|x)$ siga siendo one-hot?
7. **Colapso parcial.** En una grilla de latentes (32×32 posiciones), ¿qué significaría que el decoder use sólo algunas posiciones, o que cada posición use pocos códigos? ¿Cómo lo detectarías midiendo $\hat{q}$ por posición?
8. En el experimento de 27 bits, ¿el PixelCNN «ignora» parte de la imagen? ¿Eso es colapso o es la consecuencia deseada de un cuello de botella? ¿Dónde pondrías el límite?
9. **Redacción.** Lista los escenarios en que VQ-VAE ignora (parte de) su latente. Para cada uno, indica la causa y si la KL tiene algo que ver. Usa P4 para justificar por qué no.

Fuente: van den Oord et al. (2017), arXiv:1711.00937, sec. 3.2, 4.2 y ap. A.1. Macfarlane et al. (2026), arXiv:2604.18907, sec. 4.3. Externos (no están en tu carpeta): Łańcucki et al. (2020), arXiv:2005.08520; Huh et al. (2023), arXiv:2305.08842.

Pregunta 4: ¿Por qué deja de importar la KL?

Pregunta 4 (diap. 25)

(1) Muestra con una fórmula por qué, en VQ-VAE, la KL deja de influir en el entrenamiento. (2) Explica teóricamente y a fondo por qué ocurre, y por qué en un VAE gaussiano la KL sí empuja hacia el colapso.

Contenido: la ELBO separada en dos términos

A partir de $\mathcal{L}_{\theta,\phi}(x) = \mathbb{E}_{q_\phi(z|x)}[\log p_\theta(x,z) - \log q_\phi(z|x)]$ y $p_\theta(x,z) = p_\theta(x|z)p(z)$:

$$\mathcal{L}_{\theta,\phi}(x) = \underbrace{\mathbb{E}_{q_\phi(z|x)}[\log p_\theta(x|z)]}_{\text{reconstrucción}} - \underbrace{D_{\mathrm{KL}}\big(q_\phi(z|x) \,\|\, p(z)\big)}_{\text{regularización}}.$$

En el β-VAE (y en LPN, con $\beta \approx 10^{-4}$), el segundo término se multiplica por β.

Herramienta: tres fórmulas

- **KL discreta:** $D_{\mathrm{KL}}(q \,\|\, p) = \sum_k q_k \log \frac{q_k}{p_k}$, con la convención $0 \log 0 = 0$.
- **KL gaussiana, 1D** (verifícala):

  $$D_{\mathrm{KL}}\big(\mathcal{N}(\mu, s^2) \,\|\, \mathcal{N}(0,1)\big) = \tfrac{1}{2}\big(\mu^2 + s^2 - 1 - \log s^2\big).$$

  En d dimensiones con covarianza diagonal, se suma por coordenada.
- **Posterior agregada e información mutua:** con $x \sim p_{\text{data}}$,

  $$q(z) \coloneqq \mathbb{E}_x[q(z|x)], \qquad I_q(x;z) \coloneqq \mathbb{E}_x\big[D_{\mathrm{KL}}(q(z|x) \,\|\, q(z))\big] = H(q(z)) - \mathbb{E}_x[H(q(z|x))].$$

Contenido: la descomposición sugerida en la diapositiva

$$\mathbb{E}_x\big[D_{\mathrm{KL}}(q(z|x) \,\|\, p(z))\big] = I_q(x;z) + D_{\mathrm{KL}}\big(q(z) \,\|\, p(z)\big).$$

Se conoce como «ELBO surgery» (Hoffman y Johnson, 2016). No aparece en tus fuentes, así que tendrás que demostrarla tú.

Parte 1: la fórmula

1. Calcula $D_{\mathrm{KL}}(q(z|x) \,\|\, p(z))$ con $q(z|x) = \delta_k$ (one-hot en k) y p uniforme sobre K clases. ¿Depende de k, de x, de ϕ, de θ o de los e_j?
2. ¿Cuál es entonces su gradiente respecto a cada parámetro? Escribe la pérdida de VQ-VAE con el término que «sobrevive» y los que se añaden en su lugar.
3. ¿Seguiría siendo constante si la prior fuese aprendida al mismo tiempo (por ejemplo, un PixelCNN entrenado en conjunto)? ¿Por qué VQ-VAE entrena la prior *después*?
4. ¿Y si $q(z|x)$ fuese una categórica *no determinista* (un softmax)? Escribe la KL en función de $H(q(z|x))$. ¿Hacia dónde empujaría a q?

Parte 2: la teoría

1. Demuestra la descomposición. Pista: dentro del logaritmo, multiplica y divide por $q(z)$, y separa en dos esperanzas.
2. Interpreta los dos términos. ¿Cuál es el «costo por usar z para guardar información de x»? ¿Cuál mide si los códigos, en promedio, se parecen a la prior?
3. **VAE gaussiano.** Con la KL 1D, ¿cuál es el mínimo de $D_{\mathrm{KL}}(q(z|x) \,\|\, \mathcal{N}(0,1))$ y dónde se alcanza? Si se alcanza para todo x, ¿cuánto vale $I_q(x;z)$?
4. Retoma el Ejemplo A de P2 con $q(z|x) = \mathcal{N}(ax, s^2)$. Escribe la ELBO esperada como función de (w, a, s): reconstrucción con $\mathbb{E}[(x - wz)^2] = (1 - wa)^2\xi^2 + w^2 s^2$ y KL $= \frac{1}{2}(a^2\xi^2 + s^2 - 1 - \log s^2)$. ¿Para qué valores de ξ^2/σ'^2 el óptimo tiene $a = 0$? ¿Coincide con Li et al.?
5. **VQ-VAE.** Con q determinista, ¿cuánto vale $\mathbb{E}_x[H(q(z|x))]$? Deduce que $I_q(x;z) = H(\hat{q})$. Reemplaza en la descomposición: ¿qué identidad obtienes entre $\log K$, $H(\hat{q})$ y $D_{\mathrm{KL}}(\hat{q} \,\|\, \mathcal{U})$? ¿Qué te dice sobre la presión de la KL sobre I_q?
6. **Capacidad.** Si la KL es constante, ¿cuánta información puede llevar z como máximo? Hazlo para una posición, para una grilla de T posiciones, y para el caso de 3 latentes con $K = 512$ del paper.
7. **Redacción.** Compara: en el VAE gaussiano, ¿qué término de la descomposición castiga usar z, y con qué fuerza respecto a la reconstrucción? En VQ-VAE, ¿qué reemplaza a la KL para mantener el espacio latente «ordenado»? Termina conectando con P3: si la presión no viene de la KL, ¿de dónde viene?

Fuente: van den Oord et al. (2017), sec. 3.1. Kingma y Welling (2019), cap. 2. Externo: Hoffman y Johnson (2016), *ELBO surgery: yet another way to carve up the variational evidence lower bound*, NeurIPS Workshop on Advances in Approximate Bayesian Inference.

Pregunta 5: Comparación de los modelos

Pregunta 5 (diap. 53)

Para DreamCoder, DreamerV3, LPN y NLI, anota: (1) sus ventajas; (2) los fenómenos a considerar (el rol del posterior collapse y el de las representaciones discretas); (3) 3 o 4 principios importantes que compartan.

Contenido: ficha técnica: sólo los hechos

	DreamCoder	DreamerV3	LPN	NLI
Latente	Programa ρ simbólico, de largo variable	$s_t = \{h_t, z_t\}$, con z_t de L categóricas	$z \in \mathbb{R}^d$	$z \in (\Delta^{K-1})^T$
«Prior»	$P(\rho\|L)$, dada por la librería	$p_\phi(z_t\|h_t)$, aprendida	$\mathcal{N}(0, I)$, fija	No hay
Inferencia	$Q_\theta(\rho\|x)$ guía la búsqueda	$q_\phi(z_t\|h_t, x_t)$	$q_\phi(z\|x, y)$, promediada	q_ϕ inductor, Gumbel-Softmax
Regularizador	$\log P(L) = -\beta\,\text{size}(L)$ (MDL)	KL dyn/rep con free bits y unimix	$\beta\, D_{\text{KL}}$, $\beta \approx 10^{-4}$	$\mathcal{L}_{\text{reg}}$: tokens distintos esperados
«Sueños»	Fantasías $\rho \sim P(\rho\|L)$	Trayectorias imaginadas	No	No
Búsqueda en *test*	Enumeración guiada por Q_θ	No (*«without lookahead planning»*)	Ascenso de gradiente en z	Ascenso de gradiente en e con annealing

Contenido: DreamCoder como máquina de Helmholtz

En la fase de sueño, Q_θ se entrena maximizando $\mathbb{E}_{(x,\rho)}[\log Q_\theta(\rho|x)]$ sobre pares (x, ρ) de replays y fantasías. Es aprender una posterior aproximada *por máxima verosimilitud sobre muestras del modelo generativo*, como en la máquina de Helmholtz (Dayan et al., 1995). No hay un término $D_{\text{KL}}(Q \,\|\, \text{prior})$ que la empuje hacia la prior.

(1) Ventajas

1. Para cada modelo, ¿qué limitación de su «predecesor» resuelve? DreamCoder frente a un DSL fijo; DreamerV3 frente a ajustar hiperparámetros por dominio; LPN frente a ICL y TTT (Tabla 2 de tus notas); NLI frente a LPN (Tabla 1 del paper de NLI, en P6).
2. ¿Qué precio paga cada uno? Piensa en cómputo en test, interpretabilidad y necesidad de un DSL.

(2a) Posterior collapse

1. ¿En qué modelos hay un término que empuje la posterior hacia una prior? Escríbelo para cada uno.
2. **DreamerV3:** la prior se aprende. ¿Qué pasa con la presión hacia el colapso cuando la prior puede acercarse a la posterior? ¿Por qué $\beta_{\text{dyn}} = 1$ y $\beta_{\text{rep}} = 0.1$, y no al revés?
3. **LPN:** ¿puede el decoder $p_\theta(y|x, z)$ ignorar z? ¿Qué propiedad de la distribución de tareas (mismo x, distintos programas) lo impide? Si z colapsara, ¿qué le pasaría a la búsqueda por gradiente en test? ¿Qué sugiere $\beta \approx 10^{-4}$ sobre esta preocupación?
4. **NLI:** no hay KL, pero $\mathcal{L}_{\text{reg}}$ premia usar pocos tokens distintos. Si λ_{reg} fuera enorme,

¿hacia qué falla de P3 empujaría? ¿Qué término lo contrarresta?

5. **DreamCoder:** ¿qué significaría que $Q_\theta(\rho|x)$ ignorara x, es decir, que $Q_\theta(\rho|x) = P(\rho|L)$? ¿Qué le pasaría a la búsqueda? ¿Hay algo en el objetivo de sueño que empuje hacia eso?

(2b) Lo discreto

1. ¿Qué es discreto en cada modelo y en qué nivel: la representación, el programa o el estado del intérprete? ¿Cuál no tiene nada discreto?
2. ¿Es el mismo «beneficio de lo discreto» en DreamerV3 (Meyer et al.: ralo y binario) que en NLI (reuso y ejecución recurrente)? Argumenta con las ablaciones de P6.

(3) Principios

1. Para cada eje de la diapositiva (compresión/MDL, búsqueda en test-time, datos soñados, reutilización), escribe qué modelos lo instancian y *cómo*, con la fórmula o el componente concreto. Usa la ficha técnica.
2. ¿Hay algún eje que cumpla un solo modelo? Entonces no es un principio compartido: descártalo o reformúlalo.
3. Considera un quinto eje: «amortización + refinamiento» (encoder rápido y luego búsqueda, Sistema 1/Sistema 2). ¿En cuáles aparece? ¿Es lo mismo que «búsqueda en test-time»?
4. Elige 3 o 4 principios. Cada uno debe tener (a) un enunciado de una línea, (b) al menos dos modelos que lo instancien y (c) un contraejemplo o límite.

Fuente: Tus notas, sec. 3.1–3.4 y 5.1. Ellis et al. (2023), *Phil. Trans. R. Soc. A* 381 (en tu carpeta `Additional/rsta.2022.0050.pdf`), sec. 2 «Wake/sleep program learning». Hafner et al. (2023), ec. 3. Externo: Dayan, Hinton, Neal y Zemel (1995), *The Helmholtz Machine*, Neural Computation 7(5).

Pregunta 6: ¿NLI en un espacio continuo?

Pregunta 6 (diap. 42)

¿Por qué NLI no podría adaptarse a un espacio latente continuo manteniendo la composicionalidad?

Contenido: dónde aparece lo discreto en NLI

1. **Programa:** $z_t \in \Delta^{K-1}$, con Gumbel-Softmax en el inductor ($\tau_e : 8 \to 0.5$).
2. **Lectura del token:** $E_v^\top z_t$. Si z_t es one-hot, se lee *exactamente* una fila del code embedder.
3. **Estado del intérprete:** $\tilde{\pi}_t = \text{Softmax}((n_t + h_t)/\tau_d)$ es una distribución sobre los valores de cada celda, y se re-embebe con $s_t = E_{\text{io}}^\top \pi_t$. Aquí también hay Gumbel ($\tau_d : 2 \to 0.5$).
4. **Skip token:** $\pi_t = z_{t,\text{skip}}\, \pi_{t-1} + (1 - z_{t,\text{skip}})\, \tilde{\pi}_t$.
5. **Regularizador:** $\mathcal{L}_{\text{reg}} = \sum_{k,j} \left[1 - \prod_{b,i}(1 - q_\phi^{(k,j)})\right]$. Cada término es la probabilidad de que el token k se use al menos una vez en la posición j.

Evidencia de los papers: Macfarlane et al. (2026): Tabla 1 y Figura 3

Exactitud OOD (ID ≈ 1.00 en todos)

Método	Shift-L	Shift-P	Comp-I
LPN + gradiente	0.03	0.00	0.29
D-LPN + gradiente	0.01	0.00	0.20
NLI (sin búsqueda)	0.00	0.00	0.17
NLI + gradiente	**0.99**	**1.00**	**0.91**

D-LPN es LPN con tokens discretos (Gumbel) antepuestos a un decoder transformer, *sin* ejecución recurrente.

Ablaciones (exactitud OOD)

Base	97%
sin Gumbel en el inductor	76%
sin pérdida del encoder	66%
sin skip token	24%
sin Gumbel en el intérprete	5%
sin capa discreta	5%
sin ejecución recurrente	2%
sin programa discreto	1%

- En Shift-L, el token 231 aprende a ser «desplazar 1» y el 476, «desplazar 2». Un desplazamiento de 8 (fuera de distribución) se escribe con cuatro 231 y dos 476.
- El paper dice que la búsqueda tiene menos riesgo de sobreajuste: *«the search space is less flexible than such continuous search spaces, limited to recomposing a set of discrete embeddings»*.
- El texto no define con precisión las ablaciones «sin capa discreta» y «sin programa discreto». Si las usas como argumento, revisa el código.

Preguntas guía

1. Para cada pieza del recuadro de contenido, ¿qué pasaría si z_t fuese un vector arbitrario de $\mathbb{R}^D$? Marca las que dejan de tener sentido, las que cambian de significado y las que siguen igual.
2. **Reuso.** Con tokens continuos, ¿cuándo dos tokens son «el mismo»? Para definirlo necesitas una métrica y un umbral. ¿Qué acabas construyendo? ¿Qué pasa con $1 - \prod(1-q)$ si q ya no es una probabilidad?
3. **Composición como repetición.** Un desplazamiento de 8 aplica 231 cuatro veces. Supón que cada paso del intérprete es una función $f_v(s) = d(s, v)$, que el token aprendido es $v_{231} + \delta$, y que f es Λ-Lipschitz en s. Acota cómo crece el error en el estado después de

T pasos. ¿Qué hace el paso discreto del intérprete (punto 3 del recuadro) con ese error? Relaciónalo con «sin Gumbel en el intérprete: 5%».

4. **Tamaño del espacio de búsqueda.** ¿Cuántos programas distintos hay con T posiciones y K tokens? ¿Cuántos bits cuesta describir uno? ¿Y en un espacio continuo, a precisión arbitraria? Relaciónalo con el MDL y con Flat Minima: ¿qué prefiere la búsqueda cuando muchos programas explican los n ejemplos?

5. **D-LPN.** Es discreto, pero no tiene recurrencia, y falla. ¿Qué te dice eso sobre si lo discreto es suficiente? ¿Y «sin programa discreto: 1%» sobre si es necesario? Formula la conclusión con ambas palabras.

6. **¿«No se podría» o «sería más difícil»?** Sin Gumbel en el inductor, el modelo baja a 76%, no a 0%. Los autores conjeturan que *«the network can still learn peaked distributions»*. Si un modelo continuo termina formando grupos de vectores bien separados, ¿sigue siendo continuo en el sentido que importa? Compáralo con LPN, que es el caso continuo puro.

7. **Redacción.** Responde nombrando qué propiedad concreta se perdería en una versión verdaderamente continua: la identidad exacta de los tokens, la corrección de errores paso a paso, un espacio de hipótesis numerable, u otra. Indica qué evidencia apoya cada una. Termina contrastando con la hipótesis de los «bloques» de tus notas (sec. 3.4): ¿la evidencia apoya esa hipótesis o algo más específico?

Fuente: Macfarlane et al. (2026), arXiv:2604.18907, sec. 3, 4.1–4.3 y ap. B.1. Macfarlane et al. (2024), arXiv:2411.08706, sec. B.10 y conclusión. Tus notas, sec. 3.2–3.4.