

Aprendizaje Composicional y Generalización OOD

MAT2320-2026-Clase 16

Mircea Petrache

6 mayo 2026

Contents

1	Motivación: ¿Aprender o memorizar?	2
2	Marco Teórico: Inteligencia como Eficiencia Computacional	2
2.1	Complejidad de Kolmogorov	2
2.2	El Principio de Longitud Mínima de Descripción (MDL)	3
2.3	Inteligencia como Eficiencia Algorítmica	3
3	Benchmarks y Conjuntos de Datos	4
3.1	Generalización composicional en lenguaje	4
3.2	Razonamiento visual composicional	4
3.3	Generalización fuera de distribución: robustez	5
3.4	ARC-AGI y variantes	5
4	Síntomas de Inteligencia Algorítmica: Formulación Matemática	6
4.1	Aprendizaje por atajos (<i>Shortcut Learning</i>)	6
4.2	Generalización fuera de distribución (OOD)	6
4.3	Generalización composicional	7
4.4	Extrapolación	7
4.5	Eficiencia de muestra	8
4.6	Razonamiento causal	8
4.7	Desacoplamiento de representaciones (<i>Disentanglement</i>)	9
4.8	Razonamiento relacional y analógico	9
4.9	Robustez adversarial	10
4.10	Meta-aprendizaje	10
4.11	Aprendizaje continuo	11
4.12	Síntesis: tabla de diagnóstico	11

1 Motivación: ¿Aprender o memorizar?

La pregunta central de este curso es de naturaleza epistemológica antes que técnica: *cuando un sistema de aprendizaje automático obtiene buenos resultados en un conjunto de prueba, ¿ha aprendido el mecanismo subyacente o ha memorizado patrones de los datos de entrenamiento?*

Esta distinción tiene consecuencias prácticas inmediatas. Un modelo que ha memorizado funciona bien dentro del dominio de entrenamiento y fracasa fuera de él. Un modelo que ha aprendido un mecanismo puede extrapolar, recombinar conceptos y adaptarse a situaciones nuevas. La diferencia entre ambos casos es exactamente lo que el campo de la inteligencia artificial denomina *generalización genuina*.

La historia del campo exhibe un patrón recurrente: cada vez que un sistema de IA supera a humanos en una tarea concreta—Deep Blue en ajedrez (1997), AlphaGo en go (2016), modelos de lenguaje en olimpiadas matemáticas (2025)—surge inmediatamente la objeción de que eso no es *verdadera* inteligencia. Este desplazamiento sistemático del criterio no es arbitrario: refleja una intuición correcta de que el sistema no ha aprendido el mecanismo que un humano emplea, sino que ha optimizado otra función específica para esa tarea.

El objetivo de estas notas es formalizar esta intuición. En la Sección 2 desarrollamos un marco teórico basado en la complejidad de Kolmogorov que permite definir con precisión qué significa aprender de forma eficiente. En la Sección 3 describimos los conjuntos de datos que la comunidad utiliza para medir distintos aspectos de la generalización. En la Sección 4 formulamos matemáticamente los *síntomas* que caracterizan un sistema genuinamente inteligente, y presentamos los resultados teóricos relevantes para cada uno.

2 Marco Teórico: Inteligencia como Eficiencia Computacional

2.1 Complejidad de Kolmogorov

Sea $\mathcal{U}$ una máquina de Turing universal fijada. Para cadenas $x, y \in \{0, 1\}^*$, definimos la *complejidad de Kolmogorov condicional* como sigue.

Definición 2.1 (Complejidad de Kolmogorov). La *complejidad de Kolmogorov* de x dado y se define como

$$K(x \mid y) = \min\{|p| : \mathcal{U}(p, y) = x\},$$

donde p recorre todos los programas que producen x a partir de y en $\mathcal{U}$, y $|p|$ denota la longitud en bits de p . La complejidad *incondicional* es $K(x) = K(x \mid \varepsilon)$, con ε la cadena vacía.

Intuitivamente, $K(x)$ mide el tamaño de la descripción más corta de x : es la longitud mínima de un programa que genera x . Una cadena es *aleatoria* si su descripción más corta es esencialmente ella misma; una cadena tiene *estructura* si puede comprimirse significativamente.

Ejemplo 2.2. Sea $x_n = 0101010101 \dots 01$ (n repeticiones de 01). Entonces $K(x_n) = O(\log n)$, pues basta con el programa “imprime ‘01’ n veces”. En cambio, una cadena aleatoria $r \in \{0, 1\}^n$ satisface $K(r) \geq n - O(1)$ con probabilidad que tiende a 1.

El primer resultado fundamental es que la definición no depende esencialmente de la elección de $\mathcal{U}$.

Teorema 2.3 (Teorema de Invarianza (Kolmogorov, 1965; Li and Vitányi, 2008)). Para cualesquiera dos máquinas de Turing universales $\mathcal{U}$ y $\mathcal{V}$, existe una constante $c_{\mathcal{U}, \mathcal{V}} \geq 0$ tal que para toda cadena $x \in \{0, 1\}^*$:

$$|K_{\mathcal{U}}(x) - K_{\mathcal{V}}(x)| \leq c_{\mathcal{U}, \mathcal{V}}.$$

Idea de la demostración. Como $\mathcal{U}$ es universal, puede simular a $\mathcal{V}$: existe un programa fijo $s_{\mathcal{V}}$ de longitud c tal que $\mathcal{U}(s_{\mathcal{V}} \cdot p, y) = \mathcal{V}(p, y)$ para todo p, y . Por tanto, dado el programa mínimo p^*

para $\mathcal{V}$, el programa $s_{\mathcal{V}} \cdot p^*$ produce x en $\mathcal{U}$, con longitud $|p^*| + c$. El argumento simétrico da la otra desigualdad. $\square$

El segundo resultado fundamental establece el límite teórico del cálculo de K .

Teorema 2.4 (No computabilidad de K (Li and Vitányi, 2008)). *La función $x \mapsto K(x)$ no es computable.*

Idea de la demostración. Supongamos que existe un algoritmo que computa $K(x)$ para toda x . Entonces podemos enumerar todas las cadenas de complejidad menor que n y encontrar la más corta que no haya sido descrita por un programa de longitud $< \log_2 n$ —lo que produce una contradicción al estilo de la paradoja de Berry (se describe con pocas palabras un objeto que por definición no puede ser descrito con pocas palabras). $\square$

Algunas propiedades útiles adicionales (Li and Vitányi, 2008):

Proposición 2.5 (Propiedades básicas de K).

- (i) *Cota superior trivial:* $K(x) \leq |x| + c$ para alguna constante c .
- (ii) *Regla de la cadena:* $K(x, y) = K(x) + K(y | x) + O(\log K(x, y))$.
- (iii) *Subaditividad:* $K(x, y) \leq K(x) + K(y) + O(1)$.
- (iv) *Simetría de la información:* $K(x) + K(y | x) = K(y) + K(x | y) + O(\log K(x, y))$.

2.2 El Principio de Longitud Mínima de Descripción (MDL)

La complejidad de Kolmogorov tiene una versión aplicable que origina un criterio de selección de modelos. Sea $\mathcal{H}$ una clase de hipótesis y D un conjunto de datos.

Definición 2.6 (Principio MDL (Rissanen, 1978)). El *Principio de Longitud Mínima de Descripción* selecciona la hipótesis:

$$h^* = \arg \min_{h \in \mathcal{H}} [L(h) + L(D | h)],$$

donde $L(h)$ es la longitud en bits de la descripción de h y $L(D | h)$ es la longitud de la descripción de D dado h (el residuo o error de compresión).

El principio MDL formaliza la navaja de Occam: se prefiere la hipótesis que, al mismo tiempo, es simple y explica bien los datos. Una hipótesis que sobreajusta tiene $L(h)$ grande; una que subestima tiene $L(D | h)$ grande.

Observación 2.7. MDL y complejidad de Kolmogorov están relacionados formalmente: si $L(h) \approx K(h)$ y $L(D | h) \approx K(D | h)$, entonces MDL minimiza $K(D, h)$ que por la regla de la cadena es $K(h) + K(D | h) + O(\log(\cdot))$, i.e., la complejidad conjunta de la hipótesis y los residuos.

2.3 Inteligencia como Eficiencia Algorítmica

Con este marco, Hutter (2005) y Chollet (2019) proponen una jerarquía de agentes inteligentes basada en la eficiencia de sus representaciones internas.

Definición 2.8 (Agente más inteligente (Chollet, 2019)). Dados dos agentes A_1, A_2 con conocimiento previo $\text{priors}(A_i)$ y experiencia $\text{exp}(A_i)$, decimos que A_1 es *más inteligente* que A_2 si, para una distribución de tareas $\mathcal{T}$, la eficiencia de generalización de A_1 domina a la de A_2 :

$$\mathbb{E}_{\tau \sim \mathcal{T}} \left[\frac{\theta_{A_1}(\tau)}{K(\tau | \text{priors}(A_1))} \right] > \mathbb{E}_{\tau \sim \mathcal{T}} \left[\frac{\theta_{A_2}(\tau)}{K(\tau | \text{priors}(A_2))} \right],$$

donde $\theta_{A_i}(\tau)$ mide el rendimiento del agente A_i en la tarea τ , y $K(\tau | \text{priors}(A_i))$ es la complejidad de la tarea relativa al conocimiento previo del agente.

Esta definición captura tres aspectos: (i) un agente más inteligente resuelve las mismas tareas con algoritmos más cortos; (ii) necesita menos conocimiento previo para una tarea dada; (iii) necesita menos ejemplos para captar el mecanismo subyacente.

La limitación fundamental, consecuencia del Teorema 2.4, es que $K(\tau \mid \text{priors}(A))$ no es computable. Esta medida es una brújula teórica, no un algoritmo evaluable. Los *síntomas* de la Sección 4 son aproximaciones observables y computables a esta noción.

3 Benchmarks y Conjuntos de Datos

En esta sección describimos los conjuntos de datos que la comunidad utiliza para medir distintos aspectos de la generalización genuina. Para cada uno indicamos el tipo de generalización que evalúa, la referencia principal y una discusión breve.

3.1 Generalización composicional en lenguaje

SCAN (Lake and Baroni, 2018) —github.com/brendenlake/SCAN. SCAN (*Simplified version of the CommAI Navigation tasks*) consiste en traducir instrucciones de navegación (“jump twice and walk”) a secuencias de acciones (“JUMP JUMP WALK”). El conjunto de prueba contiene combinaciones de primitivos que no aparecen juntos en entrenamiento. Modelos seq2seq clásicos fallan catastróficamente en los splits composicionales, alcanzando menos de un 2% de exactitud en algunas particiones, frente al 100% humano.

COGS (Kim and Linzen, 2020) —github.com/najoungkim/COGS. COGS (*COmpositional Generalization challenge based on Semantic interpretation*) evalúa si modelos de lenguaje natural generalizan a estructuras sintácticas y configuraciones semánticas nuevas, como sustantivos vistos solo como sujetos de oraciones siendo usados como objetos en estructuras de control. Combina pruebas de generalización lexical y estructural, con 21 tipos de generalización definidos formalmente.

gSCAN (Ruis et al., 2020) —github.com/LauraRuis/groundedSCAN. gSCAN extiende SCAN al añadir un mundo visual: el agente debe seguir instrucciones (“push the small red box”) en una grilla 2D donde los objetos tienen atributos visuales. La generalización requerida es composicional y espacialmente situada: el modelo debe combinar acción, objeto y modificadores en contextos de disposición espacial nuevos, no vistos durante el entrenamiento.

3.2 Razonamiento visual composicional

CLEVR-CoGenT (Johnson et al., 2017) —cs.stanford.edu/people/jcjohns/clevr. CLEVR (*Compositional Language and Elementary Visual Reasoning*) genera escenas sintéticas con objetos de forma, color, material y tamaño variables, junto con preguntas de razonamiento. La variante CoGenT (*Compositional Generalization Test*) restringe el entrenamiento a combinaciones de atributos específicas (por ejemplo, esferas rojas y cubos azules) y evalúa en combinaciones no vistas (esferas azules, cubos rojos), midiendo generalización composicional de atributos visuales.

Relational Games (Barrett et al., 2018) —github.com/google-deepmind/abstract-reasoning-matrices. Un conjunto de tareas visuales abstractas diseñadas por DeepMind para aislar el razonamiento relacional: el modelo debe identificar si un conjunto de objetos satisface una relación geométrica o espacial. Los splits de generalización separan relaciones vistas en entrenamiento de relaciones nuevas entre los mismos tipos de objetos, permitiendo medir si el modelo aprendió la relación o los objetos específicos.

RAVEN (Zhang et al., 2019) —wellyzhang.github.io/project/raven. RAVEN (*Relational and Analogical Visual Reasoning*) son matrices progresivas al estilo Raven: dada una matriz 3×3 de paneles con un patrón abstracto (progresión, simetría, distribución), el modelo debe completar el noveno panel eligiendo entre candidatos. Evalúa razonamiento analógico y relacional abstracto. Los modelos de visión actuales alcanzan $\approx 60\%$ frente al $\approx 84\%$ humano.

3.3 Generalización fuera de distribución: robustez

ImageNet-C (Hendrycks and Dietterich, 2019) —github.com/hendrycks/robustness. ImageNet-C aplica 15 tipos de corrupción visual (ruido gaussiano, desenfoque, niebla, compresión JPEG, etc.) en 5 niveles de severidad a las imágenes de ImageNet de prueba. Permite medir robustez sistemática a transformaciones naturales sin modificar la distribución semántica. Modelos que funcionan bien en ImageNet-val pueden degradarse > 20 puntos porcentuales en ImageNet-C, revelando atajos basados en alta frecuencia.

ImageNet-R (Hendrycks et al., 2021) —github.com/hendrycks/imagenet-r. ImageNet-R (*Renditions*) contiene 30 000 imágenes de las 200 clases más frecuentes de ImageNet representadas en estilos distintos: pinturas, esculturas, caricaturas, origami, etc. Mide si los modelos capturaron el concepto semántico de la clase o solo las texturas fotográficas de las imágenes naturales.

WILDS (Koh et al., 2021) —wilds.stanford.edu. WILDS es una colección de 10 conjuntos de datos reales con shifts de distribución definidos por metadatos de dominio: hospital, dispositivo de captura, geografía, demografía. Incluye clasificación de imágenes médicas, predicción de propiedades moleculares y otras. Los splits de entrenamiento y prueba son distintos en dominio, no solo en instancias, lo que requiere generalización genuina a poblaciones no vistas.

DomainBed (Gulrajani and Lopez-Paz, 2021) —github.com/facebookresearch/DomainBed. DomainBed es un marco de evaluación unificado para algoritmos de generalización de dominio. Incluye 7 conjuntos de datos (PACS, VLCS, OfficeHome, TerraIncognita, entre otros) y 14 algoritmos, con protocolos de selección de hiperparámetros estandarizados. Su principal resultado es que, bajo una evaluación rigurosa, la mayoría de los métodos propuestos no superan de forma significativa a la regresión logística empírica de riesgo.

3.4 ARC-AGI y variantes

ARC-AGI (Chollet, 2019) —arcprize.org. El *Abstraction and Reasoning Corpus* consiste en tareas de completación de grillas de colores: dado 2–5 pares (entrada, salida), inferir la transformación y aplicarla a una nueva entrada. Las tareas requieren solo conocimiento previo de nivel infantil (persistencia de objetos, conteo, simetría, conectividad). Humanos alcanzan $\approx 85\%$ sin entrenamiento; modelos grandes de lenguaje estuvieron por debajo del 20% hasta 2024.

LARC (Acquaviva et al., 2022) —github.com/samacqua/LARC. LARC (*Language-Annotated ARC*) enriquece ARC con descripciones en lenguaje natural de las reglas de cada tarea, anotadas por humanos. Permite estudiar si los modelos de lenguaje-visión pueden usar descripciones verbales como andamiaje para la inferencia de la regla. Es un banco de pruebas para la interacción entre razonamiento visual abstracto y comprensión lingüística.

4 Síntomas de Inteligencia Algorítmica: Formulación Matemática

En esta sección formulamos matemáticamente los principales indicadores que la comunidad utiliza para distinguir aprendizaje genuino de memorización. Cada síntoma se presenta con una definición formal, el resultado teórico central y un ejemplo.

4.1 Aprendizaje por atajos (*Shortcut Learning*)

El aprendizaje por atajos es el modo de falla subyacente que motiva todos los demás síntomas (Geirhos et al., 2020). El criterio IRM para eliminarlo fue propuesto por Arjovsky et al. (2019).

Definición 4.1 (Característica espuria). Sea $X = (X_c, X_s) \in \mathcal{X}_c \times \mathcal{X}_s$ el espacio de entrada descompuesto en características causales X_c y espurias X_s , e $Y = f(X_c) + \eta$ la variable objetivo. Una característica X_s es *espuria* con respecto al entorno de entrenamiento e_{tr} si:

$$\text{Corr}_{e_{tr}}(X_s, Y) \neq 0 \quad \text{pero} \quad \text{Corr}_{e_{te}}(X_s, Y) = 0,$$

donde e_{te} es el entorno de prueba.

Un modelo que aprende X_s en lugar de X_c exhibirá excelente rendimiento en entrenamiento y fallo sistemático en prueba cuando cambia la distribución.

Minimización de Riesgo Invariante (IRM). Arjovsky et al. (2019) proponen un criterio para encontrar representaciones que eliminen las características espurias. Dado un conjunto de entornos $\mathcal{E}$, se busca un extractor de características $\Phi : \mathcal{X} \rightarrow \mathcal{H}$ tal que el clasificador óptimo sobre Φ sea el mismo en todos los entornos:

$$\min_{\Phi, w} \sum_{e \in \mathcal{E}} R^e(w \circ \Phi) \quad \text{s.t.} \quad w \in \arg \min_{\tilde{w}} R^e(\tilde{w} \circ \Phi) \quad \forall e \in \mathcal{E}, \quad (1)$$

donde $R^e(h) = \mathbb{E}_{(x,y) \sim e}[\ell(h(x), y)]$ es el riesgo en el entorno e . La restricción en (1) exige que w sea simultáneamente óptimo en todos los entornos, lo cual solo es posible si Φ captura las características invariantes (causales).

4.2 Generalización fuera de distribución (OOD)

Definición 4.2 (Generalización OOD). Sean $\mathcal{D}_S$ (fuente) y $\mathcal{D}_T$ (destino) distribuciones sobre $\mathcal{X} \times \mathcal{Y}$. Para una hipótesis $h : \mathcal{X} \rightarrow \mathcal{Y}$, definimos el riesgo en dominio $\mathcal{D}$ como $\varepsilon_{\mathcal{D}}(h) = \mathbb{P}_{(x,y) \sim \mathcal{D}}[h(x) \neq y]$. Decimos que h *generaliza OOD* si $\varepsilon_{\mathcal{D}_T}(h)$ es pequeño aunque $\mathcal{D}_S \neq \mathcal{D}_T$.

El resultado teórico central cuantifica cuánto puede degradarse el rendimiento al cambiar de dominio; el marco empírico para evaluarlo a escala se desarrolla en Gulrajani and Lopez-Paz (2021) y Koh et al. (2021).

Teorema 4.3 (Cota de Ben-David et al.). Sea $\mathcal{H}$ una clase de hipótesis de dimensión VC finita. Para toda $h \in \mathcal{H}$:

$$\varepsilon_T(h) \leq \varepsilon_S(h) + \frac{1}{2} d_{\mathcal{H}\Delta\mathcal{H}}(\mathcal{D}_S, \mathcal{D}_T) + \lambda,$$

donde

$$d_{\mathcal{H}\Delta\mathcal{H}}(\mathcal{D}_S, \mathcal{D}_T) = 2 \sup_{h, h' \in \mathcal{H}} |\mathbb{P}_{\mathcal{D}_S}[h(x) \neq h'(x)] - \mathbb{P}_{\mathcal{D}_T}[h(x) \neq h'(x)]|$$

es la $\mathcal{H}$ -divergencia entre dominios, y $\lambda = \min_{h^* \in \mathcal{H}} [\varepsilon_S(h^*) + \varepsilon_T(h^*)]$ es el error mínimo conjunto alcanzable.

Idea de la demostración. Se aplica la desigualdad triangular al riesgo: $\varepsilon_T(h) \leq \varepsilon_T(h^*) + \varepsilon_T(h, h^*)$, donde h^* es el óptimo conjunto. Luego se acota $\varepsilon_T(h, h^*)$ por $\varepsilon_S(h, h^*) + \frac{1}{2} d_{\mathcal{H}\Delta\mathcal{H}}$ utilizando la definición de $\mathcal{H}$ -divergencia y la desigualdad triangular en ε_S . $\square$

Observación 4.4. La $\mathcal{H}$ -divergencia es estimable a partir de datos: basta entrenar un clasificador para distinguir muestras de $\mathcal{D}_S$ de muestras de $\mathcal{D}_T$. El término λ es intrínsecamente no computable sin acceso a $\mathcal{D}_T$ etiquetada, pero en la práctica se asume pequeño. La cota revela que la brecha OOD tiene dos componentes: la distancia entre dominios (controlable con arquitectura) y el error óptimo conjunto (controlable solo con más datos del dominio destino).

4.3 Generalización composicional

La noción de composicionalidad como homomorfismo de monoides y su fallo en modelos seq2seq fue introducida empíricamente por [Lake and Baroni \(2018\)](#); la taxonomía formal de sus cinco componentes es de [Hupkes et al. \(2020\)](#).

Definición 4.5 (Generalización composicional). Sea $(\Sigma_{\text{in}}^*, \circ)$ el monóide libre sobre el alfabeto de entrada y $(\Sigma_{\text{out}}^*, \cdot)$ el monóide libre sobre el alfabeto de salida. Una función $\varphi : \Sigma_{\text{in}}^* \rightarrow \Sigma_{\text{out}}^*$ es *composicional* si es un homomorfismo de monoides:

$$\varphi(a \circ b) = \varphi(a) \cdot \varphi(b) \quad \forall a, b \in \Sigma_{\text{in}}^*.$$

Un modelo $\hat{\varphi}$ *generaliza composicionalmente* si, para todo par (a, b) no visto en entrenamiento, $\hat{\varphi}(a \circ b) = \varphi(a \circ b)$, dado que $\hat{\varphi}(a)$ y $\hat{\varphi}(b)$ son correctos.

[Hupkes et al. \(2020\)](#) descomponen la composicionalidad en cinco propiedades independientes medibles empíricamente:

- (i) **Sistematicidad:** capacidad de combinar elementos conocidos en nuevas estructuras.
- (ii) **Productividad:** generalización a composiciones de longitud arbitraria.
- (iii) **Substituibilidad:** sustitución de un elemento por otro del mismo tipo sin cambiar la estructura.
- (iv) **Locatividad:** los cambios en un sub-término afectan solo la parte correspondiente del resultado.
- (v) **Overgeneralización:** capacidad de extender la regla más allá de donde fue aprendida.

Ejemplo 4.6 (SCAN). En SCAN ([Lake and Baroni, 2018](#)), $\Sigma_{\text{in}} = \{\text{jump, walk, run, look, twice, thrice,}\dots\}$. La regla $\varphi(\text{“A twice”}) = \varphi(A) \cdot \varphi(A)$ es composicional. Un modelo entrenado con $\{\text{jump, walk twice}\}$ debe inferir $\varphi(\text{jump twice})$ sin haberlo visto. Los modelos seq2seq clásicos fallan porque no aprenden la regla de la Definición 4.5; aprenden tablas de patrones.

4.4 Extrapolación

El fallo sistemático de los transformadores en extrapolación de longitud fue documentado por [Anil et al. \(2022\)](#); la perspectiva teórica sobre activaciones polinomiales y crecimiento fuera de soporte está desarrollada en [Xu et al. \(2021\)](#).

Definición 4.7 (Extrapolación). Sea $\mathcal{D}_{\text{tr}}$ una distribución de entrenamiento soportada en $\mathcal{S}_R = \{x \in \mathcal{X} : \|x\| \leq R\}$. Decimos que un modelo $\hat{f}$ *extrapola* si su error en $\mathcal{S}_{R'} \setminus \mathcal{S}_R$ con $R' > R$ es comparable a su error en $\mathcal{S}_R$.

La extrapolación es la forma más severa de OOD: el punto de prueba cae fuera del soporte convexo de los datos de entrenamiento. Las redes neuronales tienden a producir predicciones arbitrarias en esta región porque no tienen ninguna restricción sobre cómo extender la función aprendida.

Un caso especialmente estudiado es la *length generalization* en transformers: un transformador entrenado en secuencias de longitud $\leq n$ falla para longitudes $n + k$ en tareas simples como copiar, invertir o sumar, incluso si la arquitectura admite longitudes arbitrarias. Esto evidencia que el modelo no aprendió el algoritmo sino una función que lo aproxima en el rango visto.

Proposición 4.8. *Para una red neuronal con función de activación polinomial de grado d , el valor de la red en un punto x fuera del soporte convexo de los datos de entrenamiento puede crecer como $O(\|x\|^d)$. En particular, la extrapolación no está controlada por la pérdida de entrenamiento.*

4.5 Eficiencia de muestra

La eficiencia de muestra es la manifestación práctica de la complejidad de Kolmogorov (Definición 2.8): un sistema que aprendió un mecanismo más comprimido necesita menos ejemplos para actualizarlo.

Definición 4.9 (Aprendizaje PAC (Shalev-Shwartz and Ben-David, 2014)). Una clase de hipótesis $\mathcal{H}$ es *PAC-aprendible* si existe un algoritmo A y una función $m_{\mathcal{H}} : (0, 1)^2 \rightarrow \mathbb{N}$ tal que para toda distribución $\mathcal{D}$, todo $\varepsilon, \delta \in (0, 1)$, y toda muestra de tamaño $m \geq m_{\mathcal{H}}(\varepsilon, \delta)$, con probabilidad $\geq 1 - \delta$:

$$\varepsilon_{\mathcal{D}}(A(S)) \leq \min_{h \in \mathcal{H}} \varepsilon_{\mathcal{D}}(h) + \varepsilon.$$

Teorema 4.10 (Complejidad de muestra via dimensión VC (Vapnik and Chervonenkis, 1971)). *Sea $\mathcal{H}$ una clase de hipótesis con dimensión VC $d_{\text{VC}}(\mathcal{H}) = d < \infty$. Entonces $\mathcal{H}$ es PAC-aprendible con complejidad de muestra:*

$$m_{\mathcal{H}}(\varepsilon, \delta) = O\left(\frac{d + \log(1/\delta)}{\varepsilon}\right).$$

Recíprocamente, toda clase con $d_{\text{VC}} = d$ requiere $\Omega\left(\frac{d + \log(1/\delta)}{\varepsilon}\right)$ muestras.

Observación 4.11. El Teorema 4.10 muestra que la complejidad de muestra crece con la riqueza de la clase $\mathcal{H}$. Para modelos modernos de aprendizaje profundo, d_{VC} es vastamente superior al tamaño del conjunto de entrenamiento, lo que hace que las cotas clásicas sean poco informativas. Sin embargo, en la práctica los modelos generalizan—fenómeno que motiva teorías más finas basadas en márgenes, normas espectrales y complejidad de Rademacher.

4.6 Razonamiento causal

El marco formal de los SCMs y la jerarquía de niveles causales se debe a Pearl (2009); un tratamiento orientado al aprendizaje automático se encuentra en Schölkopf et al. (2021).

Definición 4.12 (Modelo causal estructural (Pearl, 2009)). Un *Modelo Causal Estructural (SCM)* es una tupla $\mathcal{M} = (\mathbf{V}, \mathbf{U}, \mathcal{F}, P_{\mathbf{U}})$ donde:

- $\mathbf{V} = \{V_1, \dots, V_n\}$ son las variables endógenas (observadas),
- $\mathbf{U} = \{U_1, \dots, U_k\}$ son las variables exógenas (ruido),
- $\mathcal{F} = \{f_1, \dots, f_n\}$ son funciones estructurales con $V_i = f_i(\text{Pa}(V_i), U_i)$,
- $P_{\mathbf{U}}$ es la distribución conjunta sobre $\mathbf{U}$.

El *grafo causal* $G(\mathcal{M})$ tiene un arco $V_j \rightarrow V_i$ si $V_j \in \text{Pa}(V_i)$.

Pearl (2009) establece una jerarquía de tres niveles de consultas causales:

- (I) **Asociación:** $P(Y \mid X = x)$. Inferencia puramente estadística, accesible sin intervención.
- (II) **Intervención:** $P(Y \mid \text{do}(X = x))$. Efecto de forzar $X = x$ independientemente de sus causas. Formalmente, $\text{do}(X = x)$ reemplaza la ecuación f_X por la constante x , eliminando todos los arcos entrantes a X en $G(\mathcal{M})$.
- (III) **Contrafactual:** $P(Y_{X=x}(u) = y)$. Valor de Y en el mundo hipotético donde $X = x$, para el individuo con ruido $U = u$ observado en el mundo real.

Teorema 4.13 (Identificabilidad de intervenciones (Pearl, 2009)). *En un SCM con grafo acíclico dirigido G , el efecto causal $P(Y \mid \text{do}(X = x))$ es identificable a partir de datos observacionales si y solo si no existe camino de puerta trasera (backdoor path) no bloqueado entre X e Y . En ese caso:*

$$P(Y \mid \text{do}(X = x)) = \sum_z P(Y \mid X = x, Z = z) P(Z = z),$$

donde Z es cualquier conjunto de ajuste válido que bloquea todos los caminos de puerta trasera.

Los modelos de aprendizaje profundo actuales operan exclusivamente en el nivel (I): aprenden $P(Y \mid X)$ desde datos observacionales. El acceso a los niveles (II) y (III) requiere información sobre la estructura causal del problema, que generalmente no se puede inferir solo desde observaciones sin supuestos adicionales.

4.7 Desacoplamiento de representaciones (*Disentanglement*)

La noción formal de desacoplamiento vía correlación total fue popularizada por el β -VAE (Higgins et al., 2017); el resultado de imposibilidad es de Locatello et al. (2019).

Definición 4.14 (Representación desacoplada). Sea $z = (z_1, \dots, z_k) \in \mathbb{R}^k$ un vector latente con distribución $p(z)$. Decimos que z es *desacoplado* si sus componentes son mutuamente independientes:

$$p(z) = \prod_{i=1}^k p(z_i),$$

o equivalentemente, la información mutua entre cualesquiera dos componentes es cero: $I(z_i; z_j) = 0$ para todo $i \neq j$. El *grado de acoplamiento* se mide mediante la correlación total:

$$\text{TC}(z) = \text{KL}\left(p(z) \parallel \prod_{i=1}^k p(z_i)\right) \geq 0.$$

Un resultado fundamental de Locatello et al. (2019) pone en cuestión la posibilidad de aprender representaciones desacopladas sin supervisión:

Teorema 4.15 (Imposibilidad del desacoplamiento no supervisado (Locatello et al., 2019)). *Sea $p(x)$ una distribución de observaciones generada por un modelo generativo latente $p(x \mid z)p(z)$. Para cualquier conjunto de representaciones desacopladas z que explique $p(x)$, existe un conjunto infinito de representaciones alternativas z' estadísticamente indistinguibles de z bajo $p(x)$ pero arbitrariamente acopladas. En particular, el desacoplamiento no es identificable a partir de datos i.i.d. sin sesgo inductivo adicional.*

Idea de la demostración. Sea $h : \mathbb{R}^k \rightarrow \mathbb{R}^k$ una transformación que preserva el volumen (por ejemplo, una rotación). Entonces $p(x \mid z)p(z) = p(x \mid h^{-1}(z'))p(z')$ con $z' = h(z)$, y $p(x)$ es idéntica bajo ambas representaciones. La representación z' es, en general, acoplada aunque z no lo sea. Sin supuestos adicionales sobre h , no hay forma de distinguir las dos soluciones. $\square$

Este resultado implica que el desacoplamiento como criterio de entrenamiento requiere algún sesgo inductivo explícito (por ejemplo, invarianzas conocidas, etiquetas parciales o restricciones arquitectónicas).

4.8 Razonamiento relacional y analógico

El estudio sistemático del razonamiento relacional en redes neuronales usando matrices abstractas proviene de Barrett et al. (2018); la evaluación con matrices progresivas de Raven es de Zhang et al. (2019).

Definición 4.16 (Razonamiento relacional). Sea $\mathcal{O}$ un conjunto de objetos y $\mathcal{R}$ un conjunto de relaciones $R : \mathcal{O}^k \rightarrow \{0, 1\}$. Un modelo *razona relacionamente* si, dado un nuevo conjunto de objetos $\mathcal{O}'$ disjunto de los objetos de entrenamiento, puede evaluar correctamente relaciones $R \in \mathcal{R}$ sobre $\mathcal{O}'$.

El razonamiento analógico es un caso especial: dada una relación de correspondencia $A : B :: C : ?$, el sistema debe encontrar D tal que la relación entre C y D sea isomorfa a la relación entre A y B . Formalmente, si $\rho(A, B) = \rho(C, D)$ para alguna función de semejanza relacional ρ , entonces D es la respuesta correcta.

Este tipo de razonamiento es exactamente lo que evalúan las matrices de Raven (RAVEN, Sección 3): el patrón de la matriz define la relación ρ implícitamente, y el modelo debe inferir ρ y aplicarla. La dificultad reside en que ρ es distinta para cada tarea, lo que requiere generalización OOD al nivel de relaciones.

4.9 Robustez adversarial

Los ataques adversariales del tipo FGSM fueron introducidos por Goodfellow et al. (2015); la robustez certificada por suavizado aleatorio es de Cohen et al. (2019).

Definición 4.17 (Robustez adversarial). Sea $f : \mathcal{X} \rightarrow \mathcal{Y}$ un clasificador y $\|\cdot\|_p$ una norma en $\mathcal{X}$. Decimos que f es (ε, δ) -robusto si:

$$\mathbb{P}_{x \sim \mathcal{D}}[\forall \xi \text{ con } \|\xi\|_p \leq \varepsilon, f(x + \xi) = f(x)] \geq 1 - \delta.$$

La robustez adversarial se puede certificar mediante suavizado aleatorio (Cohen et al., 2019):

Teorema 4.18 (Robustez certificada por suavizado aleatorio (Cohen et al., 2019)). Sea $f : \mathcal{X} \rightarrow \mathcal{Y}$ un clasificador base y $g(x) = \arg \max_c \mathbb{P}_{\eta \sim \mathcal{N}(0, \sigma^2 I)}[f(x + \eta) = c]$ el clasificador suavizado. Si la clase de mayor probabilidad para x es c_A con probabilidad $\underline{p}_A$ y la segunda clase c_B con probabilidad $\bar{p}_B \leq \underline{p}_A$, entonces g es consistente en toda la bola $\|x' - x\|_2 \leq R$ con

$$R = \frac{\sigma}{2} \left(\Phi^{-1}(\underline{p}_A) - \Phi^{-1}(\bar{p}_B) \right),$$

donde Φ^{-1} es la función cuantil de la normal estándar.

Desde la perspectiva del aprendizaje genuino, la fragilidad adversarial es un síntoma de aprendizaje por atajos: el modelo aprendió una función que aproxima bien la decisión correcta en el dominio de entrenamiento pero que carece de regularidad (baja constante de Lipschitz) en regiones vecinas. Un clasificador *genuinamente* robusto debería satisfacer una cota de Lipschitz $\|f(x) - f(x')\|_\infty \leq L\|x - x'\|_p$ con L razonablemente pequeña.

4.10 Meta-aprendizaje

El objetivo MAML fue propuesto por Finn et al. (2017); su análisis de convergencia es de Fallah et al. (2020).

Definición 4.19 (Meta-aprendizaje). Sea $p(\tau)$ una distribución sobre tareas $\tau = (\mathcal{D}_\tau^{\text{tr}}, \mathcal{D}_\tau^{\text{te}})$. El problema de meta-aprendizaje busca un parámetro inicial θ^* tal que, para cualquier tarea nueva $\tau \sim p(\tau)$, el gradiente de un paso desde θ^* produce un buen modelo en $\mathcal{D}_\tau^{\text{te}}$:

$$\theta^* = \arg \min_{\theta} \mathbb{E}_{\tau \sim p(\tau)} [\mathcal{L}_\tau(\theta - \alpha \nabla_{\theta} \mathcal{L}_\tau(\theta))],$$

donde $\mathcal{L}_\tau(\theta) = \mathbb{E}_{(x, y) \sim \mathcal{D}_\tau^{\text{tr}}} [\ell(f_\theta(x), y)]$. Este es el objetivo de *Model-Agnostic Meta-Learning* (MAML) (Finn et al., 2017).

Teorema 4.20 (Convergencia de MAML (Fallah et al., 2020)). Sea $F(\theta) = \mathbb{E}_\tau[\mathcal{L}_\tau(\theta')]$ con $\theta' = \theta - \alpha \nabla \mathcal{L}_\tau(\theta)$. Bajo supuestos de suavidad (la pérdida es L -suave y ρ -Hessiana-Lipschitz) y una tasa de aprendizaje externa $\beta = O(1/(LT^{1/2}))$, el gradiente descendente estocástico sobre θ satisface:

$$\frac{1}{T} \sum_{t=0}^{T-1} \mathbb{E}[\|\nabla F(\theta^{(t)})\|^2] \leq O\left(\frac{1}{\sqrt{T}}\right).$$

La conexión con la Sección 4.3 es directa: el meta-aprendizaje exitoso implica que θ^* captura alguna *representación de la estructura del espacio de tareas*, lo cual requiere que las tareas tengan componentes reutilizables —es decir, que la distribución $p(\tau)$ tenga estructura composicional.

4.11 Aprendizaje continuo

El olvido catastrófico fue identificado en redes conexionistas por McCloskey and Cohen (1989); la regularización EWC basada en información de Fisher es de Kirkpatrick et al. (2017).

Definición 4.21 (Olvido catastrófico (McCloskey and Cohen, 1989)). Sea $\theta_1^* = \arg \min_\theta \mathcal{L}_1(\theta)$ los parámetros óptimos para la tarea $\mathcal{T}_1$. Decimos que el modelo *olvida catastróficamente* al aprender $\mathcal{T}_2$ si:

$$\mathcal{L}_1\left(\arg \min_\theta \mathcal{L}_2(\theta)\right) \gg \mathcal{L}_1(\theta_1^*).$$

La causa fundamental es geométrica: las regiones de parámetros óptimas para $\mathcal{T}_1$ y $\mathcal{T}_2$ pueden ser disjuntas en el espacio de parámetros, y el descenso de gradiente sobre $\mathcal{L}_2$ aleja θ de la región óptima para $\mathcal{L}_1$.

Consolidación elástica de pesos (EWC). Kirkpatrick et al. (2017) proponen regularizar la actualización con la información de Fisher de la primera tarea:

$$\mathcal{L}(\theta) = \mathcal{L}_2(\theta) + \frac{\lambda}{2} \sum_i F_i (\theta_i - \theta_{1,i}^*)^2, \quad (2)$$

donde $F_i = \mathbb{E}_{x \sim \mathcal{D}_1} \left[\left(\frac{\partial \log p(y|x, \theta)}{\partial \theta_i} \right)^2 \right]$ es el elemento i -ésimo de la diagonal de la matriz de información de Fisher en θ_1^* . El término (2) penaliza cambios en parámetros que fueron importantes para $\mathcal{T}_1$, equilibrando plasticidad (aprendizaje de $\mathcal{T}_2$) y estabilidad (retención de $\mathcal{T}_1$).

4.12 Síntesis: tabla de diagnostico

La Tabla 1 resume los síntomas presentados en esta sección, con el criterio de medición y la evaluación aproximada para los modelos de lenguaje grande actuales.

References

- Sarah Acquaviva, Yewen Pu, Marta Kryven, Theodora Laude, Cedegao Wong, Joshua B. Eater, Joshua B. Tenenbaum, and Brenden M. Lake. Communicating natural programs to humans and machines. In *Advances in Neural Information Processing Systems (NeurIPS)*, 2022.
- Cem Anil, Yuhuai Wu, Anders Andreassen, Aitor Lewkowycz, Vedant Misra, Vinay Ramasesh, Ambrose Slone, Guy Gur-Ari, Ethan Dyer, and Behnam Neyshabur. Exploring length generalization in large language models. *Advances in Neural Information Processing Systems (NeurIPS)*, 35, 2022.
- Martin Arjovsky, Léon Bottou, Ishaan Gulrajani, and David Lopez-Paz. Invariant risk minimization. In *arXiv preprint arXiv:1907.02893*, 2019.

Síntoma	Criterio formal	Medible?	LLMs (aprox.)
Atajos espurios	Def. 4.1 / IRM	Sí	Frecuente
Generaliz. OOD	Teo. 4.3	Sí	Parcialmente
Composicionalidad	Def. 4.5	Sí	Deficiente
Extrapolación	§4.4	Sí	Deficiente
Eficiencia de muestra	Teo. 4.10	Sí	Mejorando
Razonamiento causal	Def. 4.12 (nivel II–III)	Difícil	Deficiente
Desacoplamiento	Teo. 4.15	Difícil	Incierto
Razonamiento relacional	§4.8	Sí	Parcialmente
Robustez adversarial	Def. 4.17	Sí	Deficiente
Meta-aprendizaje	Def. 4.19	Sí	Parcialmente
Aprendizaje continuo	Def. 4.21	Sí	Deficiente

Table 1: Resumen de síntomas de inteligencia algorítmica.

David G. T. Barrett, Felix Hill, Adam Santoro, Ari S. Morcos, and Timothy Lillicrap. Measuring abstract reasoning in neural networks. In *Proceedings of the 35th International Conference on Machine Learning (ICML)*, pages 511–520, 2018.

François Chollet. On the measure of intelligence. *arXiv preprint arXiv:1911.01547*, 2019.

Jeremy Cohen, Elan Rosenfeld, and J. Zico Kolter. Certified adversarial robustness via randomized smoothing. In *Proceedings of the 36th International Conference on Machine Learning (ICML)*, pages 1310–1320, 2019.

Alireza Fallah, Aryan Mokhtari, and Asuman Ozdaglar. On the convergence theory of gradient-based model-agnostic meta-learning algorithms. In *Proceedings of the 23rd International Conference on Artificial Intelligence and Statistics (AISTATS)*, 2020.

Chelsea Finn, Pieter Abbeel, and Sergey Levine. Model-agnostic meta-learning for fast adaptation of deep networks. In *Proceedings of the 34th International Conference on Machine Learning (ICML)*, pages 1126–1135, 2017.

Robert Geirhos, Jörn-Henrik Jacobsen, Claudio Michaelis, Matthew Zeiler, Wieland Brendel, Matthias Bethge, and Felix A. Wichmann. Shortcut learning in deep neural networks. *Nature Machine Intelligence*, 2:665–673, 2020.

Ian J. Goodfellow, Jonathon Shlens, and Christian Szegedy. Explaining and harnessing adversarial examples. In *International Conference on Learning Representations (ICLR)*, 2015.

Ishaan Gulrajani and David Lopez-Paz. In search of lost domain generalization. *International Conference on Learning Representations (ICLR)*, 2021.

Dan Hendrycks and Thomas Dietterich. Benchmarking neural network robustness to common corruptions and perturbations. In *International Conference on Learning Representations (ICLR)*, 2019.

Dan Hendrycks, Steven Basart, Norman Mu, Saurav Kadavath, Frank Wang, Evan Dorundo, Rahul Desai, Tyler Zhu, Samyak Parajuli, Mike Guo, et al. The many faces of robustness: A critical analysis of out-of-distribution generalization. *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 2021.

Irina Higgins, Loic Matthey, Arka Pal, Christopher Burgess, Xavier Glorot, Matthew Botvinick, Shakir Mohamed, and Alexander Lerchner. beta-VAE: Learning basic visual concepts with a constrained variational framework. In *International Conference on Learning Representations (ICLR)*, 2017.

- Dieuwke Hupkes, Verna Dankers, Mathijs Mul, and Elia Bruni. Compositionality decomposed: How do neural networks generalise? *Journal of Artificial Intelligence Research*, 67:757–795, 2020.
- Marcus Hutter. *Universal Artificial Intelligence: Sequential Decisions Based on Algorithmic Probability*. Springer, 2005.
- Justin Johnson, Bharath Hariharan, Laurens van der Maaten, Li Fei-Fei, C. Lawrence Zitnick, and Ross Girshick. CLEVR: A diagnostic dataset for compositional language and elementary visual reasoning. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 2901–2910, 2017.
- Najoung Kim and Tal Linzen. COGS: A compositional generalization challenge based on semantic interpretation. In *Proceedings of the 2020 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, pages 9087–9105, 2020.
- James Kirkpatrick, Razvan Pascanu, Neil Rabinowitz, Joel Veness, Guillaume Desjardins, Andrei A. Rusu, Kieran Milan, John Quan, Tiago Ramalho, Agnieszka Grabska-Barwinska, et al. Overcoming catastrophic forgetting in neural networks. *Proceedings of the National Academy of Sciences*, 114(13):3521–3526, 2017.
- Pang Wei Koh, Shiori Sagawa, Henrik Marklund, Sang Michael Xie, Marvin Zhang, Akshay Balsubramani, Wenlong Hu, Michihiro Yasunaga, Richard Lanus Phillips, Irena Gao, et al. WILDS: A benchmark of in-the-wild distribution shifts. In *Proceedings of the 38th International Conference on Machine Learning (ICML)*, 2021.
- Andrei N. Kolmogorov. Three approaches to the quantitative definition of information. *Problems of Information Transmission*, 1(1):1–7, 1965.
- Brenden M. Lake and Marco Baroni. Generalization without systematicity: On the compositional skills of sequence-to-sequence recurrent networks. In *Proceedings of the 35th International Conference on Machine Learning (ICML)*, 2018.
- Ming Li and Paul Vitányi. *An Introduction to Kolmogorov Complexity and Its Applications*. Springer, 3rd edition, 2008.
- Francesco Locatello, Stefan Bauer, Mario Lucic, Gunnar Rätsch, Sylvain Gelly, Bernhard Schölkopf, and Olivier Bachem. Challenging common assumptions in the unsupervised learning of disentangled representations. In *Proceedings of the 36th International Conference on Machine Learning (ICML)*, pages 4114–4124, 2019.
- Michael McCloskey and Neal J. Cohen. Catastrophic interference in connectionist networks: The sequential learning problem. *Psychology of Learning and Motivation*, 24:109–165, 1989.
- Judea Pearl. *Causality: Models, Reasoning, and Inference*. Cambridge University Press, 2nd edition, 2009.
- Jorma Rissanen. Modeling by shortest data description. *Automatica*, 14(5):465–471, 1978.
- Laura Ruis, Jacob Andreas, Marco Baroni, Diane Bouchacourt, and Brenden M. Lake. A benchmark for systematic generalization in grounded language understanding. *Advances in Neural Information Processing Systems (NeurIPS)*, 33, 2020.
- Bernhard Schölkopf, Francesco Locatello, Stefan Bauer, Nan Rosemary Ke, Nal Kalchbrenner, Anirudh Goyal, and Yoshua Bengio. Toward causal representation learning. *Proceedings of the IEEE*, 109(5):612–634, 2021.

- Shai Shalev-Shwartz and Shai Ben-David. *Understanding Machine Learning: From Theory to Algorithms*. Cambridge University Press, 2014.
- Vladimir N. Vapnik and Alexey Ya. Chervonenkis. On the uniform convergence of relative frequencies of events to their probabilities. *Theory of Probability and Its Applications*, 16(2): 264–280, 1971.
- Keyulu Xu, Mozhi Zhang, Jingling Li, Simon S. Du, Ken-ichi Kawarabayashi, and Stefanie Jegelka. How neural networks extrapolate: From feedforward to graph neural networks. *International Conference on Learning Representations (ICLR)*, 2021.
- Chi Zhang, Feng Gao, Baoxiong Jia, Yixin Zhu, and Song-Chun Zhu. RAVEN: A dataset for relational and analogical visual reasoning. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 5317–5327, 2019.